

Framework de Explicabilidade de Indicadores de Qualidade de Telecomunicações

Segmentação e explicabilidade dos **5.570 municípios brasileiros** por qualidade de serviços de telecomunicações — combinando K-Means, HDBSCAN, LOF e SHAP sobre dados RQUAL (Anatel) e IBGE.

Resumo

Este trabalho apresenta um framework analítico de múltiplas camadas para segmentar e explicar a qualidade de serviços de telecomunicações nos 5.570 municípios brasileiros. Combinando indicadores RQUAL (Anatel) com dados socioeconômicos e geográficos do IBGE, aplicamos K-Means (K=5, silhouette=0,831) para identificar cinco perfis municipais distintos — de capitais metropolitanas a municípios norte-amazônicos com cobertura crítica. Sobre essa segmentação, aplicamos HDBSCAN para descoberta de sub-estruturas por coesão de grupo, LOF para detecção de anomalias individuais, SHAP sobre um modelo surrogate (Random Forest, accuracy=95,0% ± 0,6%) para explicar quais variáveis definem cada perfil, e um **Índice de Invisibilidade à Média (IV)** combinado com matched pairs intracluster para identificar municípios com contexto comparável mas desfechos operacionais sistematicamente divergentes. O achado central é que **a classificação de municípios norte-amazônicos é determinada pela extensão territorial (|SHAP|=0,355), não pelos indicadores de serviço** — e que C3 é o cluster com maior densidade de municípios invisíveis (IV médio 1,36), com o par mais divergente sendo Ibarama/RS ↔ Tunas/RS (score 47,8). Os resultados subsidiam priorização regulatória e políticas de investimento diferenciadas por perfil territorial.

1. Introdução

A Anatel publica anualmente o **RQUAL** — um sistema de 8 indicadores que medem a qualidade dos serviços de telecomunicações por município: taxa de reclamações, atendimento, resolução no prazo, disponibilidade, velocidade de download, cobertura de infraestrutura e throughput. O Brasil, porém, é um território de extremos: os 5.570 municípios variam de capitais com densidade de 13.000 hab/km² a municípios amazônicos com área superior à da Bélgica e economia essencialmente primária. Aplicar políticas regulatórias uniformes sobre essa heterogeneidade significa tratar Curitiba e Tefé (AM) pelo mesmo instrumento.

A pergunta central deste framework: *É possível segmentar os municípios brasileiros em perfis coerentes que expliquem, simultaneamente, sua qualidade de telecom e seu contexto socioeconômico-territorial?*

Para respondê-la, construímos um pipeline em 11 etapas — da coleta e integração de dados até a formalização de municípios *invisíveis à média* via matched pairs intracluster. O resultado não é apenas uma classificação: é uma **tipologia regulatória** com identificação de exceções e rastreabilidade de decisão para cada um dos 5.570 municípios.

2. Dados

2.1 Fontes

Fonte	Provedor	Cobertura	Volume
-------	----------	-----------	--------

RQUAL	Anatel (dados abertos)	2022–2025, todos os estados	5,96M linhas
PIB Municipal	IBGE	5.570 municípios, 2021	—
Censo demográfico	IBGE	5.570 municípios, 2022	—
Taxa de urbanização	IBGE	5.570 municípios, 2022	—
IDHM	PNUD/Atlas Brasil	5.570 municípios, 2010	—
Geometria municipal	IBGE via geobr	5.570 municípios, 2020	—

Chave de integração: `cod_mun` — código IBGE de 7 dígitos. Preferido sobre nome do município por ser numérico e padronizado (evita inconsistências como "São Luís" vs "Sao Luis").

2.2 Indicadores RQUAL

Indicador	Descrição	Interpretação
IND2	Taxa de Reclamações	Menor = melhor
IND4	Taxa de Atendimento	Maior = melhor
IND5	Taxa de Solução no Prazo	Maior = melhor
IND8	Disponibilidade do Serviço	Maior = melhor
IND9	Velocidade de Download	Maior = melhor
INF1	Cobertura/Infraestrutura	Maior = melhor
INF4-UP	Throughput Upload	Maior = melhor

2.3 Variáveis socioeconômicas (IBGE)

`pib_per_capita`, `pib_agropecuaria`, `pib_industria`, `pib_servicos`, `pop_total`, `pop_rural`, `densidade`, `area_km2`, `tx_urbanizacao`, `idhm`, `lat`, `lon` + dummies regionais (Norte, Nordeste, Centro-Oeste, Sul/Sudeste).

3. Metodologia

3.1 Visão geral do pipeline

```
flowchart TD
    A["12 XLSX RQUAL\n(por estado)"] --> B["NB01: Unificação\n5,96M linhas"]
    B --> C["NB02: Filtro 2022\n5.570 municípios × 11 col"]
    D["5 fontes IBGE\nPIB · Pop · IDHM · Coords"] --> E["NB03: Agregação IBGE\n5.570 × 56 col"]
    C --> F["NB04: Integração\nRQUAL + IBGE\n5.570 × 78 col"]
    E --> F
    F --> G["NB05: Feature Selection\nCorrelação + VIF\n5.570 × 20 features"]
    G --> H["NB06: K-Means K=5\n+ HDBSCAN local\nrqual_2022_clusterizado"]
    H --> I["NB07: Interpretação\nHeatmap · Radar · Mapa\n+ ANOVA/Kruskal-Wallis"]
```

```
H --> J["NB08: UMAP + LOF\n559 excepcionais\nrqual_2022_clusterizado_v2"]
J --> K["NB09: HDBSCAN u LOF\n763 excepcionais\ncomparacao_achados.csv"]
J --> L["NB10: SHAP\n5.570 explicações
individuais\nshap_explicacoes_municipios.csv"]
L --> M["NB11: Invisibilidade à Média\nÍndice IV + Matched Pairs\n4.033 pares
intracluster"]
```

3.2 Feature Selection (NB05)

A partir de 78 variáveis brutas, o pipeline de seleção reduziu para **20 features** em 6 etapas com logs de auditoria:

Etapa	Método	Resultado
1. Higienização	Remoção de constantes e quasi-constantes ($\geq 99\%$ dominância)	41 variáveis avaliadas → 40 mantidas
2. Imputação	Mediana por UF com fallback mediana global	4 variáveis socioeconômicas imputadas
3. Robustez	Winsorização 1%–99% para variáveis com $ \text{skew} > 2$	IND2, IND4, IND8 e outras
4. Z-score	Padronização (média=0, desvio=1)	Todas as features numéricas
5. Correlação	Remoção de pares $ \rho \geq 0,80$ (preservando os 8 RQUAL)	20 variáveis removidas
6. VIF iterativo	Remoção até $VIF \leq 5,0$ (tolerância 10,0 para RQUAL)	1 variável removida (URB__Total, $VIF=5,28$)

Features finais (20): 7 indicadores RQUAL · PIB agropecuário · PIB industrial · PIB per capita · área · densidade · população rural · IDHM · lat · lon · 4 dummies regionais

3.3 Clustering K-Means (NB06)

- **Scaler:** RobustScaler — fração de outliers medida: 2,47% (acima do limiar de 2% para preferir Robust sobre Standard)
- **Avaliação:** K=2 a K=12, 5 seeds aleatórias (42, 7, 123, 2025, 99), 25 inicializações por rodada
- **Rank ponderado:** Calinski-Harabász $\times 2,0$ + Davies-Bouldin $\times 1,5$ + Silhouette $\times 1,2$ + Inércia $\times 1,0$

K	Silhouette	Calinski-Harabász	Score ponderado
2	0,831	5.659	−18,7 ✓ melhor silhouette
5	0,620	4.159	−28,3 ✓ escolhido
12	0,156	3.266	−51,5

Por que K=5 e não K=2? K=2 tem o maior silhouette, mas produz apenas dois macro-grupos (Sul/Sudeste vs restante), perdendo as nuances do Nordeste, Norte e Capitais. K=5 equilibra separação com granularidade interpretativa.

3.4 Detecção de Municípios Excepcionais (NB08 + NB09)


Três abordagens testadas para identificar municípios que fogem do padrão do seu próprio cluster:

Abordagem	Taxa de ruído	Municípios	Papel
HDBSCAN direto (20D)	96,3% ✖	204	Descartado — maldição da dimensionalidade
UMAP (10D) + HDBSCAN	27,6% ✔	204	Retido — sub-estruturas por coesão de grupo
LOF por cluster	N/A (score contínuo) ✔	559	Adotado — anomalias individuais, cobre todos os clusters

3.5 Explicabilidade SHAP (NB10)

K-Means não tem função de decisão interpretável. A abordagem surrogate resolve isso em duas etapas:

- 1. **Surrogate Random Forest:** treinado para reproduzir os labels K-Means (accuracy CV-5: **95,0% ± 0,6%**)
- 2. **SHAP TreeExplainer:** aplicado ao RF para gerar valores SHAP para todos os 5.570 municípios em 16 features analíticas



A matriz de confusão confirma que o surrogate reproduz a segmentação K-Means com alta fidelidade — garantindo que os valores SHAP explicam os clusters reais, não um proxy degradado.


4. Resultados

4.1 Cinco perfis de municípios

Cluster	Municípios	Perfil
C0 — Urbano-Avançado	216 (3,9%)	Alto PIB, alto IDHM, excelente upload — Sul/Sudeste
C1 — Intermediário	3.054 (54,8%)	Desempenho médio nacional — padrão de referência
C2 — Nordeste Periférico	2.057 (36,9%)	Infraestrutura existe, mas SLA fraco — Nordeste
C3 — Norte/Amazônico	216 (3,9%)	Pior atendimento e resolução — municípios remotos

C4 — Capitais/Destaques	27 (0,5%)	Benchmark nacional — 1 município por UF
-------------------------	-----------	---

Perfil médio por cluster (z-scores)




O heatmap mostra os valores médios padronizados de cada cluster nos indicadores RQUAL e nas variáveis socioeconômicas. Valores positivos (verde) indicam desempenho acima da média nacional; negativos (vermelho), abaixo.

Destaques:



- **C3** apresenta $IND4 = -1,70\sigma$ e $IND5 = -2,09\sigma$ — os piores índices de atendimento e resolução do país
- **C4** lidera em densidade ($+2,06\sigma$), PIB industrial ($+1,99\sigma$) e IDHM ($+1,63\sigma$)
- **C0** se destaca em throughput de upload ($+1,24\sigma$) e velocidade de download ($+0,54\sigma$)

Comparação dos indicadores RQUAL por cluster



O radar evidencia a separação entre os clusters: C3 (vermelho) afunda em IND4 e IND5, enquanto C0 e C4 dominam em INF4-UP e IND9.


Distribuição geográfica




A segmentação reflete a estrutura regional do Brasil: **C0** é 67% Sudeste · **C2** é 84% Nordeste · **C3** é 68% Norte · **C4** distribui-se por todas as regiões.

Distribuição dos indicadores e cobertura por cluster

Distribuição dos indicadores RQUAL por cluster




Municípios excepcionais por método e cluster
LOF cobre todos os clusters; HDBSCAN só detectou C0 e C3




4.2 Validação estatística da segmentação

Para confirmar que a separação entre clusters não é artefato do algoritmo, aplicamos **ANOVA paramétrica** e **teste de Kruskal-Wallis** (não-paramétrico) sobre os 14 indicadores.



Resultado: todos os 14 indicadores apresentam $p < 0,001$ nos dois testes — a separação entre os 5 clusters é estatisticamente significativa em todas as dimensões. Os indicadores com maior poder discriminatório são `area_km2`, `lat`, `idhm` e `IND5` — alinhando-se com os achados SHAP (seção 5.3).

4.3 Projeção UMAP





A projeção UMAP em 2D ilustra a estrutura de separação aprendida pelo K-Means no espaço de 20 features. C3 e C4 formam ilhas compactas; C1 e C2 ocupam regiões contíguas com fronteira suave; C0 aparece como satélite de C4 — consistente com o achado SHAP de que ambos são movidos pelas mesmas features (`pib_industria`, `densidade`).

5. Discussão dos Resultados

5.1 Sub-estruturas internas — HDBSCAN

O HDBSCAN revelou sub-estruturas densas em C0 e C3: **204 municípios (3,7%)** formaram 4 sub-clusters com alto valor analítico — municípios similares entre si que divergem do padrão geral do cluster pai.



C3 — Norte/Amazônico: dois padrões opostos dentro do pior cluster




Grupo	Mun.	IND4	IND5	Perfil
Ruído	85	-1,77	-2,28	Caso mais crítico — sem conectividade nem qualidade operacional
Sub-0 — Amazônia profunda	112	-1,81	-2,19	PA, AM, AC, RR — atendimento crítico, mas IND9 acima da média (+0,14)
Sub-1 — Agronegócio MT/MS	19	-0,76	-0,59	Exceção positiva — remotos e rurais, mas qualidade muito superior

Sub-cluster Agronegócio MT/MS: 19 municípios de MT (15), MS (3) e MG (1) — Tangará da Serra, Campo Novo do Parecis, Canarana, Cáceres, Juína. Apesar de serem extensos, rurais e classificados no "pior cluster" pelo K-Means, a dinâmica do agronegócio viabilizou qualidade radicalmente superior: IND5 salta de $-2,19\sigma$ para $-0,59\sigma$. São a prova de que o contexto geográfico não é impeditivo quando há investimento.

Validação: Sub-cluster Agronegócio MT/MS — HDBSCAN vs LOF



C0 — Urbano-Avançado: dois tipos de excelência



Grupo	Mun.	IND4	INF4-UP	Perfil
Sub-0 — Elite total	50	-0,12	+1,51	SP (28), MG, RJ — topo absoluto em todos os indicadores
Sub-1 — Gargalo de atendimento	23	-0,37	+1,36	SP (11), RJ (6) — alta velocidade, mas atendimento sobrecarregado


Sub-cluster Gargalo metrópoles: infraestrutura de ponta (INF4-UP +1,36 σ , IND9 +0,70 σ) mas IND4 negativo — o volume de chamados nas grandes metrópoles supera a capacidade das operadoras. Fenômeno de saturação operacional, não técnica.

5.2 Municípios excepcionais — LOF


O LOF identificou **559 municípios excepcionais** (10% por cluster) com combinações atípicas de indicadores, cobrindo todos os 5 clusters — incluindo C1 e C2, que eram analiticamente opacos ao HDBSCAN.

LOF score > 1,5 como limiar de alta excentricidade. Score máximo observado: **2,266** (Águas de São Pedro/SP).

Tentativa 3: Local Outlier Factor (LOF)



Municípios Excepcionais (LOF)
Distribuição Geográfica
(tamanho do ponto $\propto$ LOF score)



C1 — Intermediário: 306 excepcionais

O maior cluster concentra os maiores extremos individuais do país — municípios normais na maioria dos indicadores, mas com um ou dois em valores impossíveis para o contexto.

Município	UF	LOF	Padrão atípico
Águas de São Pedro	SP	2,27	Alta velocidade (+1,12σ) com cobertura fraca — acesso premium em estância balneária
Tunas	RS	1,88	IND4 = -4,06σ e IND5 = -4,31σ — colapso de atendimento
Silvanópolis	TO	1,82	Pior IND9 do cluster (-4,11σ) com cobertura acima da média
São Vendelino	RS	1,89	IND2 = +4,28σ — caso extremo de insatisfação
Camargo	RS	1,99	Upload excepcional (+3,10σ) — desvio positivo isolado

C2 — Nordeste Periférico: 206 excepcionais

Município	UF	LOF	Padrão atípico
São Bento do Norte	RN	2,23	Alta IND4 com IND5 negativo — atende mas não resolve
Fernando de Noronha	PE	2,01	IND4 = IND5 = -4,33σ — isolamento geográfico extremo
Curionópolis	PA	1,98	IND8 = -4,16σ — único no C2 com disponibilidade crítica
Arapiraca	AL	1,84	Upload elevado (+1,71σ) — contrasta com o perfil típico do Nordeste


C4 — Capitais/Destaques: 3 excepcionais


Município	UF	LOF	Padrão atípico
Porto Velho	RO	1,29	Upload elevado, IND5 levemente negativo — capital amazônica fora do perfil
Brasília	DF	1,18	Upload excepcionalmente alto (+1,31σ) — concentração de infraestrutura federal
Rio Branco	AC	1,09	Maior upload do C4 (+2,20σ) — investimento desproporcional

As 3 capitais excepcionais são amazônicas — perfil de upload elevado combinado com SLA levemente abaixo do esperado para o cluster.

5.3 Explicabilidade por cluster — SHAP


SHAP Summary — Importância global das features
(média sobre os 5 clusters)





O que realmente define cada cluster

Cluster	Feature dominante	SHAP	O que isso revela
C0 — Urbano-Avançado	pib_industria	0,323	PIB industrial — não qualidade RQUAL — define a elite
C1 — Intermediário	idhm + lat	0,132	Desenvolvimento humano + posição geográfica (Sul/Sudeste)
C2 — Nordeste Periférico	idhm + lat + lon	0,197	A localização geográfica explica o cluster melhor que os indicadores de telecom
C3 — Norte/Amazônico	area_km2	0,355	A extensão territorial domina — classificado pelo tamanho antes da qualidade do serviço
C4 — Capitais	pib_industria + densidade	0,096	Mesmas features do C0, em escala urbana máxima



Três achados que mudam a interpretação regulatória

1. C3 é criado pela geografia, não pelo serviço

`area_km2` tem $|SHAP| = 0,355$ — mais que o dobro do segundo lugar em qualquer cluster. Municípios norte-amazônicos são agrupados por sua imensidão territorial *antes* dos indicadores de qualidade. A má qualidade de telecom no C3 é *consequência* do contexto geográfico, não causa da classificação. A política regulatória deve atacar a barreira territorial, não apenas o indicador de SLA.


2. C2 é definido pela localização, não pelo IDHM isolado

`lat` e `lon` somam $|SHAP| = 0,264$ no C2 — o Nordeste é tão geograficamente coeso que as coordenadas identificam o cluster quase tão bem quanto os indicadores socioeconômicos. Isso confirma que a qualidade operacional inferior do C2 tem raízes estruturalmente regionais.

3. C0 e C4 são movidos pelo mesmo motor


`pib_industria` domina em ambos os clusters de alta performance. A distinção entre "municípios avançados" e "capitais" é de escala, não de natureza — capitais têm mais do mesmo que os melhores municípios não-capitais.

Waterfall — explicações individuais



Os gráficos waterfall mostram, para municípios representativos de cada cluster, quais features contribuíram positiva ou negativamente para a classificação. Cada município tem sua explicação individual registrada em `shap_explicacoes_municipios.csv`.

SHAP nos municípios excepcionais LOF



Os municípios excepcionais tendem a ter uma **feature com valor SHAP desproporcional** em relação ao restante do cluster — confirmando que sua excentricidade é direcionada, não ruído aleatório. Fernando de


Noronha, por exemplo, é dominado por lon e IND4 em direções opostas ao perfil do C2.


5.4 Ortogonalidade entre HDBSCAN e LOF

Sobreposição HDBSCAN n LOF: 0 municípios — resultado esperado e revelador.

Tipo de excepcionalidade	Método	O que detecta
Exceção de grupo	HDBSCAN	Municípios similares entre si que formam sub-grupo coeso distinto do cluster pai
Exceção individual	LOF	Município isolado, sem vizinhança densa — anomalia pontual

Os métodos medem **dimensões ortogonais** da excepcionalidade: um município em sub-cluster HDBSCAN tem LOF score baixo (está rodeado de similares). Um outlier LOF não forma sub-cluster (está isolado, sem grupo coeso). **Confirmação estatística:** Mann-Whitney U — municípios HDBSCAN têm LOF score significativamente menor ($p < 0,001$).





763 municípios excepcionais na união: 204 por coesão de grupo (HDBSCAN) + 559 por isolamento individual (LOF).


Exportados com tipo de excepcionalidade em `comparacao_achados_hdbscan_lof.csv`.

5.5 Invisibilidade à Média — Índice IV e Matched Pairs (NB11)

Municípios dentro do mesmo cluster podem ter contexto socioeconômico comparável e, ainda assim, apresentar desfechos operacionais radicalmente diferentes. Esse fenômeno — aqui formalizado como **invisibilidade à média** — não é capturado por nenhum dos métodos anteriores: nem o K-Means (que agrupa por proximidade global), nem o LOF (que detecta anomalias individuais), nem o HDBSCAN (que detecta coesão de grupo).

Índice IV: quantifica o desvio de cada município em relação ao centróide do seu cluster nas dimensões operacionais (RQUAL), ponderando cada indicador pelo peso SHAP do cluster.

$$IV_i = \sum_j w_{\{c\}} \cdot |z_{\{ij\}} - \bar{z}_{\{c\}}|$$



Cluster	IV médio	IV mediano	IV máximo
C4 Capitais	0,22	0,21	0,47 — cluster mais homogêneo
C0 Urbano-Avançado	0,35	0,28	1,45
C1 Intermediário	0,56	0,46	3,63 — Tunas/RS
C2 Nordeste Periférico	0,81	0,76	3,37
C3 Norte/Amazônico	1,36	1,33	2,79 — cluster mais invisível

C3 tem o maior IV médio — não apenas é o pior cluster, como é o mais internamente heterogêneo. C4, ao contrário, é o mais homogêneo: capitais convergem para um padrão comum.

Matched pairs intracluster: identificação de pares de municípios no mesmo cluster com contexto socioeconômico similar (distância euclidiana no espaço de features IBGE) e desfecho operacional divergente (distância no espaço RQUAL). Total: **4.033 pares**.




Cluster	Pares
C0 Urbano-Avançado	90
C1 Intermediário	2.319
C2 Nordeste Periférico	1.485

Par mais divergente: Ibarama/RS ↔ Tunas/RS (score 47,8) — municípios gaúchos com contexto praticamente idêntico, mas Tunas tem $IND4 = -4,06\sigma$ e $IND5 = -4,31\sigma$ enquanto Ibarama opera próximo da média do cluster.

Indicador dominante da divergência por cluster:

- C0: **INF4-UP** — upload define os extremos no cluster de excelência
- C1 e C2: **IND5** — resolução no prazo é o principal divisor interno
- C3: **IND4** — taxa de atendimento separa os municípios amazônicos entre si



Os matched pairs são a matéria-prima regulatória mais valiosa do framework: provam que o problema não é o cluster inteiro, mas municípios específicos que poderiam ter melhor desempenho dado seu contexto — e que estão invisíveis à média.

5.6 Visão Consolidada por Cluster

Síntese 360° integrando segmentação, explicabilidade (SHAP) e municípios excepcionais:

Cluster	N (%)	Features SHAP dominantes	Outliers LOF	Sub-grupos HDBSCAN	Prioridade regulatória
C0 Urbano-Avançado	216 (3,9%)	pib_industria, densidade, idhm	22	2 (elite total + gargalo SP/RJ)	Manutenção
C1 Intermediário	3.054 (54,8%)	idhm, lat, pib_per_capita	306	—	Monitoramento
C2 Nordeste Periférico	2.057 (36,9%)	idhm, lat, lon	206	—	Alta
C3 Norte/Amazônico	216 (3,9%)	area_km2, lon, IND5	22	2 (Amazônia profunda + Agronegócio MT/MS)	Crítica

C4 Capitais	27 (0,5%)	pib_industria, densidade, idhm	3	—	Benchmark
--------------------	--------------	-----------------------------------	---	---	-----------

6. Implicações para Políticas Públicas

Os resultados apontam para intervenções regulatórias distintas por perfil — não por indicador isolado. A chave da contribuição analítica deste framework é que os drivers de cada cluster, revelados pelo SHAP, orientam *onde* e *como* intervir.

C3 — Norte/Amazônico: atacar a barreira territorial, não o SLA

O SHAP confirma que `area_km2` domina a classificação ($|SHAP|=0,355$). Esses municípios não chegam ao C3 por má gestão operacional, mas por isolamento estrutural. Políticas de cobertura (satélite, roteamento alternativo, subsídio de infraestrutura) têm mais impacto do que metas de SLA aplicadas a operadoras sem infraestrutura viável. O sub-cluster do Agronegócio MT/MS é a prova empírica: condições geográficas similares, mas investimento privado viabilizou qualidade radicalmente superior (IND5 salta de $-2,19\sigma$ para $-0,59\sigma$).

C2 — Nordeste Periférico: maturidade operacional, não expansão de rede

A rede existe (INF1 acima da média). O problema é operacional: IND5 (resolução no prazo) e IND2 (reclamações) são os indicadores mais negativos. Políticas de SLA rigoroso e incentivos à eficiência de atendimento são mais eficientes do que novas licenças de cobertura. O SHAP revela que `lat / lon` explicam tanto quanto o IDHM — confirmando que a fragilidade tem raízes estruturalmente regionais que transcendem qualquer operadora individual.

C1 — Intermediário: vigilância nos extremos individuais

O LOF revela 306 exceções individuais no maior cluster — municípios que parecem normais em média, mas têm um indicador em colapso (Tunas/RS: $IND5 = -4,31\sigma$). Monitoramento automatizado via LOF score permite identificação precoce antes que o problema se consolide como padrão.

C0 / C4 — Benchmark: replicabilidade como política

Os dois clusters de alta performance têm o mesmo motor (PIB industrial + densidade). O sub-cluster de gargalo do C0 — municípios SP/RJ com IND4 negativo apesar de infraestrutura de ponta — mostra que mesmo a elite pode saturar operacionalmente. Políticas de capacidade de atendimento (não técnica) são o instrumento correto aqui.

7. Reprodutibilidade

Pipeline detalhado

Notebook 01 — Leitura e Unificação RQUAL

`notebooks/01-Leitura e união de todos os estados.ipynb`

Entrada: 12 arquivos XLSX por agrupamento de estados

Saída: `base_RQUAL_unificada.parquet` — **5.962.723 linhas × 19 colunas**

- Leitura paralela com `ThreadPoolExecutor` (8 workers) — engine `calamine` (~3x mais rápido que `openpyxl` em arquivos grandes)

- Coluna `__arquivo_origem` para rastreabilidade por estado
 - Cobertura: 2022–2025, 8 indicadores, todas as UFs
-

Notebook 02 — Preparação do Ano Base

`notebooks/02-Análise, Seleção e Preparação de ano base.ipynb`

Entrada: `base_RQUAL_unificada.parquet`

Saída: `rqual_2022_consolidado_clean.parquet` — **5.570 linhas × 11 colunas**

- Filtro para 2022 — único ano com cobertura completa dos 8 indicadores para a maioria dos municípios
 - Agregação municipal: média anual por indicador
 - Imputação por mediana da UF (fallback: mediana nacional)
 - Logs: `rqual_2022_log_imputacao.csv` , `auditoria_imputacao_resumo.csv`
-

Notebook 03 — Agregação IBGE

`notebooks/03-Agregacao_Dados_Socio-Economicos1_PATCHED.ipynb`

Entrada: 5 fontes IBGE independentes (PIB, população/área, urbanização, IDHM, lat/lon)

Saída: `base_socioeconomica_completa.xlsx` — **5.570 municípios × 56 colunas**

- Merge progressivo por `cod_mun`
 - Normalização Unicode NFKD para joins robustos (remove acentos sem truncar nomes)
 - Coordenadas corrigidas: fonte IBGE armazena lat/lon como inteiros ×10.000 (e.g. -167573 → -16,7573°); divisão aplicada com assertivas de validação
-

Notebook 04 — Integração RQUAL + IBGE

`notebooks/04-Integracao e Analise de Variaveis RQUAL+SocioEc.ipynb`

Entrada: RQUAL 2022 (5.570 × 11) + IBGE (5.570 × 56)

Saída: `rqual_2022_integrado.parquet` — **5.570 linhas × 78 colunas**

- Join left por `cod_mun` — todos os 5.570 municípios preservados
 - Zero municípios sem dados socioeconômicos após merge
-

Notebook 05 — Feature Selection

`notebooks/05-Seleção de feicoes.ipynb`

Entrada: `rqual_2022_integrado.parquet` (5.570 × 78)

Saída: `rqual_2022_feats_reduzidas.parquet` — **5.570 linhas × 20 features**

Logs: `log_poda_correlacao.csv` , `log_vif_iterativo.csv` ,
`log_zscore_validacao_completo.csv` , `log_imputacao_socio.csv` ,
`log_robustez_transformacoes.csv`

Notebook 06 — Clustering K-Means + HDBSCAN

`notebooks/06-Kmeans.ipynb`

Entrada: `rqual_2022_feats_reduzidas.parquet`

Saída: `rqual_2022_clusterizado.parquet`

Artefatos: `kmeans_model.pkl` , `scaler_final.pkl` , `kmeans_metricas_por_K.csv` ,
`kmeans_escolha_config.json`

Notebook 07 — Interpretação dos Clusters

`notebooks/07-Interpretacao_Clusters.ipynb`

Saída: heatmap · radar · mapa geográfico · distribuição regional · boxplots · ANOVA/Kruskal-Wallis ·
`tabela_resumo_clusters.csv`

Notebook 08 — UMAP + HDBSCAN vs LOF

`notebooks/08-UMAP_HDBSCAN_LOF.ipynb`

Saída: `rqual_2022_clusterizado_v2.parquet` (com `umap_x` , `umap_y` , `lof_score` ,
`lof_outlier`) + `municipios_excepcionais_lof.csv`

Notebook 09 — Comparação HDBSCAN vs LOF

`notebooks/09-Comparacao_Achados_HDBSCAN_vs_LOF.ipynb`

Saída: `comparacao_achados_hdbscan_lof.csv` — **763 municípios excepcionais (HDBSCAN u LOF)**
com tipo de excepcionalidade

Notebook 10 — SHAP: Explicabilidade por Cluster

`notebooks/10-SHAP_Explicabilidade_Clusters.ipynb`

Saída: `shap_importancia_por_cluster.csv` · `shap_explicacoes_municipios.csv` ·
`shap_matrix_completa.csv`

Notebook 11 — Invisibilidade à Média e Matched Pairs Intracluster

`notebooks/11-Invisibilidade_Media_Matched_Pairs.ipynb`

Entrada: `rqual_2022_clusterizado.csv` · `shap_importancia_por_cluster.csv` ·
`shap_explicacoes_municipios.csv`

Saída: `iv_invisibilidade_municipios.csv` · `matched_pairs_intracluster.csv`

O que foi feito:

- Cálculo do Índice IV (invisibilidade à média) para os 5.570 municípios — desvio ponderado por SHAP em relação ao centróide do cluster
 - C3 Norte/Amazônico identificado como o cluster mais internamente heterogêneo (IV médio 1,36)
 - Identificação de 4.033 matched pairs intracluster: mesmo cluster, contexto socioeconômico similar, desfecho RQUAL divergente
 - Par mais divergente: Ibarama/RS ↔ Tunas/RS (score 47,8)
 - Indicador dominante da divergência: `IND5` em C1 e C2, `INF4-UP` em C0, `IND4` em C3
 - Casos ilustrativos com narrativa regulatória para os top-3 pares por cluster
-

Instalação

```
git clone https://github.com/mfidosjr/Framework-Explicabilidade-Indicadores.git
cd Framework-Explicabilidade-Indicadores
pip install -r requirements.txt
```

Alguns arquivos XLSX de dados brutos (50–80 MB) são armazenados diretamente no repositório. Para arquivos maiores, use `git lfs pull`.

Artefatos principais

Arquivo	Localização	Descrição
base_RQUAL_unificada.parquet	data/interim/	RQUAL nacional (5,96M × 19)
rqual_2022_consolidado_clean.parquet	data/interim/	RQUAL 2022 agregado por município
rqual_2022_integrado.parquet	data/interim/	Base integrada RQUAL+IBGE (5.570 × 78)
rqual_2022_feats_reduzidas.parquet	data/interim/	20 features selecionadas para clustering
rqual_2022_clusterizado.parquet	data/interim/	K-Means K=5 + HDBSCAN local (v1)
rqual_2022_clusterizado_v2.parquet	data/interim/	Base enriquecida com UMAP coords + LOF score
municipios_excepcionais_lof.csv	data/output/	559 municípios excepcionais (LOF, 10% por cluster)
comparacao_achados_hdbscan_lof.csv	data/output/	763 municípios excepcionais (HDBSCAN u LOF, com tipo)
kmeans_model.pkl	models/	Modelo K-Means treinado (K=5)
scaler_final.pkl	models/	RobustScaler ajustado
kmeans_metricas_por_K.csv	data/output/	Métricas de avaliação K=2 a K=12
tabela_resumo_clusters.csv	data/output/	Perfil médio por cluster
shap_importancia_por_cluster.csv	data/output/	Importância SHAP feature × cluster (16 × 5)
shap_explicacoes_municipios.csv	data/output/	Feature dominante + SHAP de cada município (5.570 linhas)
shap_matrix_completa.csv	data/output/	Matriz completa de valores SHAP (5.570 × 16)
iv_invisibilidade_municipios.csv	data/output/	Índice IV de invisibilidade à média (5.570 municípios)
matched_pairs_intracluster.csv	data/output/	4.033 pares matched (contexto similar, desfecho divergente)

Módulos Python (src/)

Módulo	Funções principais
data_loader.py	load_rqual_parallel(), load_ibge_socioeconomico(), load_parquet()
feature_engineering.py	impute_by_uf(), remove_high_correlation(), run_vif_iterative(), validate_zscore()
clustering.py	evaluate_kmeans_range(), choose_best_k(), run_hdbscan_per_cluster(), save_clustering_artifacts()

Documentação técnica

- [Documentacao/RQUALCDUST10112022.pdf](#) — Manual técnico RQUAL (Anatel)
 - [Documentacao/Glossario_de_Termos_Indicadores de Qualidade dos Serviços RQUAL_V2.odt](#) — Glossário de termos
-

Tecnologias

- Python 3.10+ · pandas · numpy · scipy
- scikit-learn · hdbscan · umap-learn · shap
- pyarrow · openpyxl · python-calamine
- matplotlib · seaborn · geobr
- Jupyter Notebooks