Framework de Explicabilidade de Indicadores de Qualidade de Telecomunicações

Framework analítico para segmentação e explicabilidade de municípios brasileiros com base em indicadores de qualidade de serviços de telecomunicações (RQUAL/Anatel) cruzados com dados socioeconômicos e geográficos do IBGE.

Objetivo

Identificar padrões e agrupamentos entre os **5.570 municípios brasileiros** combinando:

- **Indicadores RQUAL** (Anatel): 8 indicadores de qualidade de telecomunicações
- **Dados IBGE**: PIB, população, densidade, urbanização, IDHM, coordenadas geográficas

O resultado é uma segmentação hierárquica (K-Means → HDBSCAN) que permite interpretar o contexto socioeconômico e territorial associado à qualidade do serviço em cada município, subsidiando políticas regulatórias e priorização de investimentos.

Resultados: 5 perfis de municípios

O modelo identificou **5 clusters** com características distintas de qualidade e contexto socioeconômico:

Cluster	Municípios	Perfil
C0 — Urbano-Avançado	216 (3,9%)	Alto PIB, alto IDHM, excelente upload — Sul/Sudeste
C1 — Intermediário	3.054 (54,8%)	Desempenho médio nacional — padrão de referência
C2 — Nordeste Periférico	2.057 (36,9%)	Infraestrutura existe, mas SLA fraco — Nordeste
C3 — Norte/Amazônico	216 (3,9%)	Pior atendimento e resolução — municípios remotos
C4 — Capitais/Destaques	27 (0,5%)	Benchmark nacional — 1 município por UF

Perfil médio por cluster (z-scores)

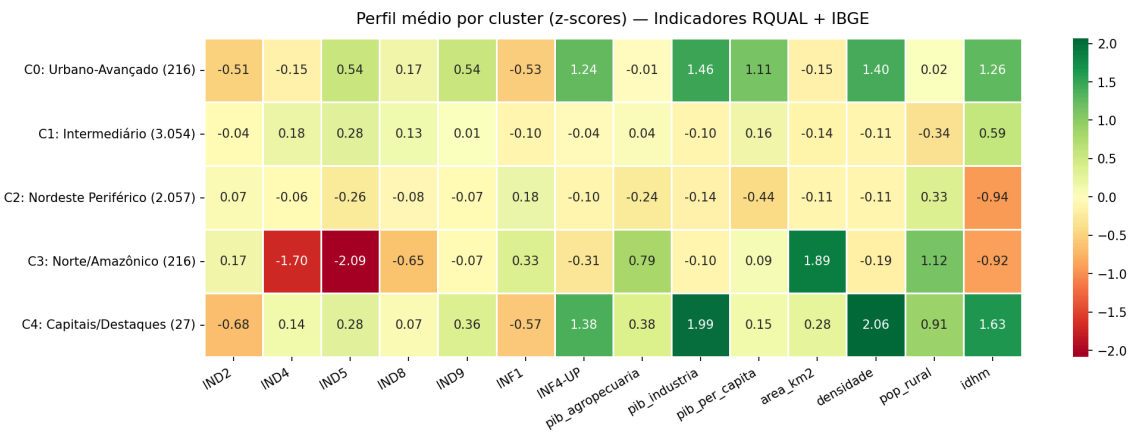

O heatmap mostra os valores médios padronizados (z-score) de cada cluster nos indicadores RQUAL e nas variáveis socioeconômicas do IBGE. Valores positivos (verde) indicam desempenho acima da média nacional; negativos (vermelho), abaixo.

Destaques:

- **C3 (Norte/Amazônico)** apresenta IND4 = −1,70σ e IND5 = −2,09σ — os piores índices de atendimento e resolução de todo o país
- **C4 (Capitais)** lidera em densidade demográfica (+2,06σ), PIB industrial (+1,99σ) e IDHM (+1,63σ)
- **C0 (Urbano-Avançado)** se destaca em throughput de upload (+1,24σ) e velocidade de download (+0,54σ)

Comparação dos indicadores RQUAL por cluster

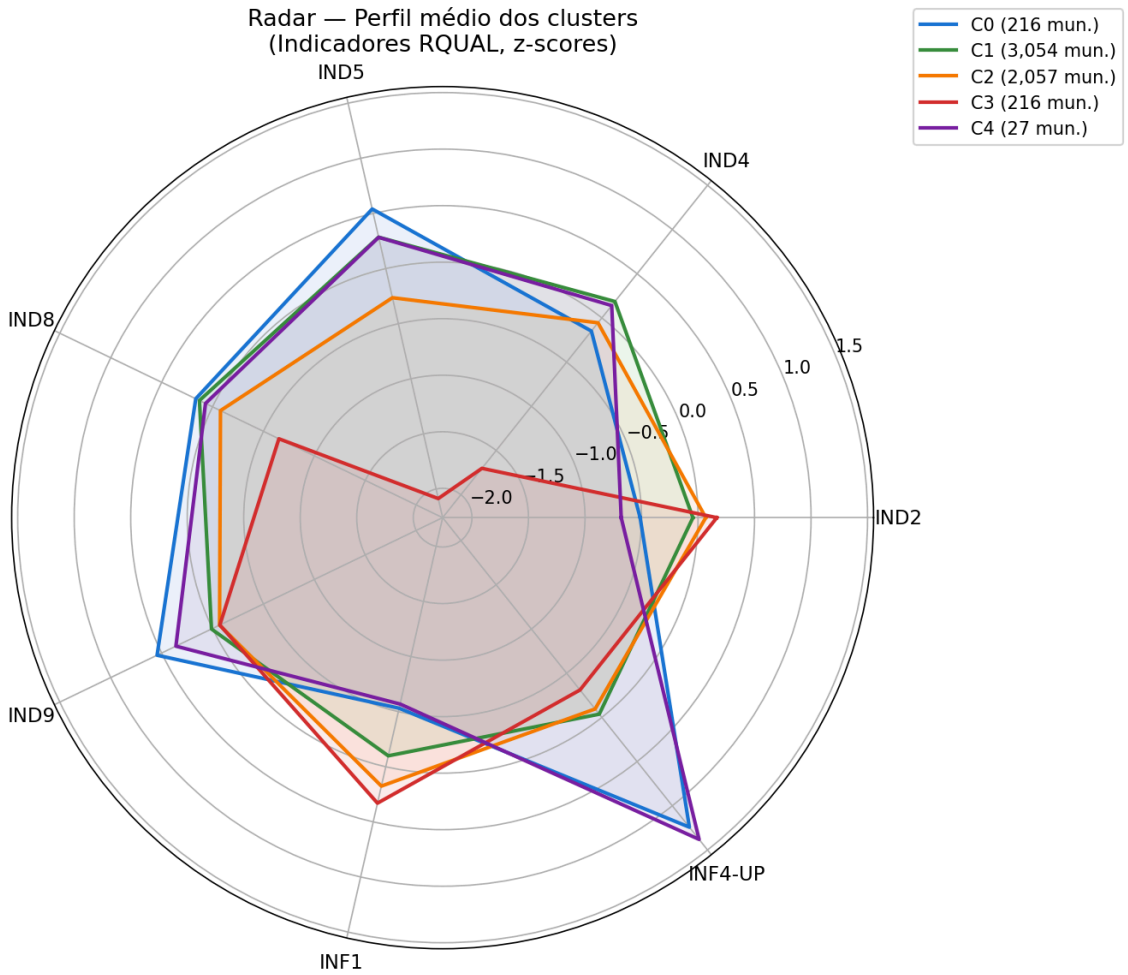

O radar evidencia a separação entre os clusters: C3 (vermelho) afunda em IND4 e IND5, enquanto C0 e C4 (azul e roxo) dominam em INF4-UP e IND9.

Composição regional e distribuição geográfica

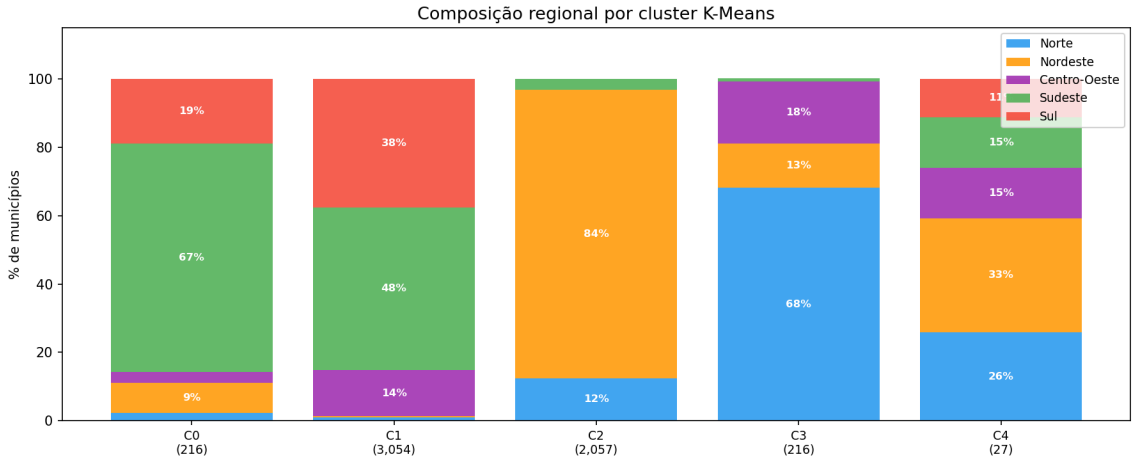

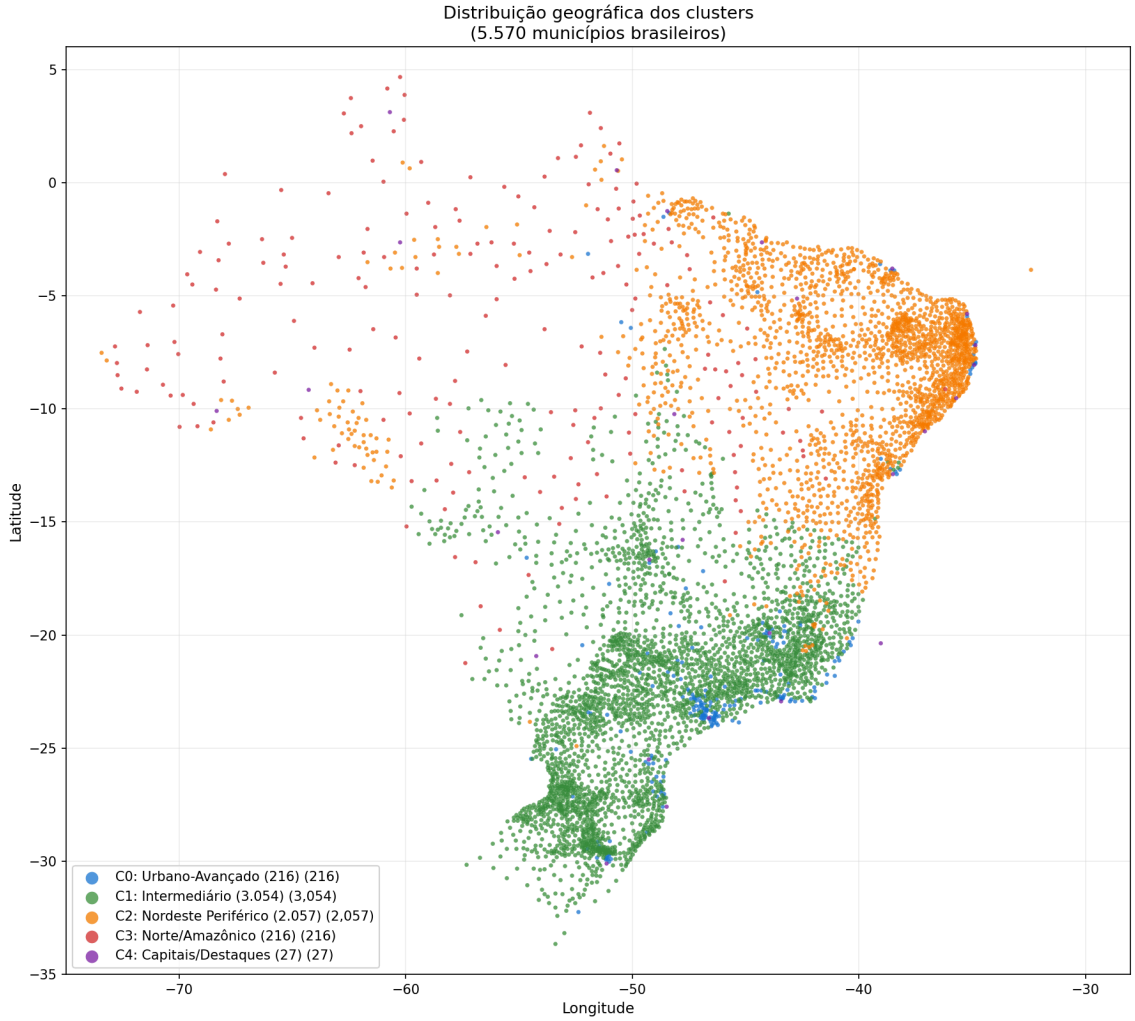

A segmentação reflete fortemente a estrutura regional do Brasil:

- **C0** é 67% Sudeste | **C1** é 48% Sudeste + 38% Sul
- **C2** é 84% Nordeste | **C3** é 68% Norte

- **C4** distribui-se por todas as regiões (1 capital por UF)

Distribuição dos indicadores por cluster

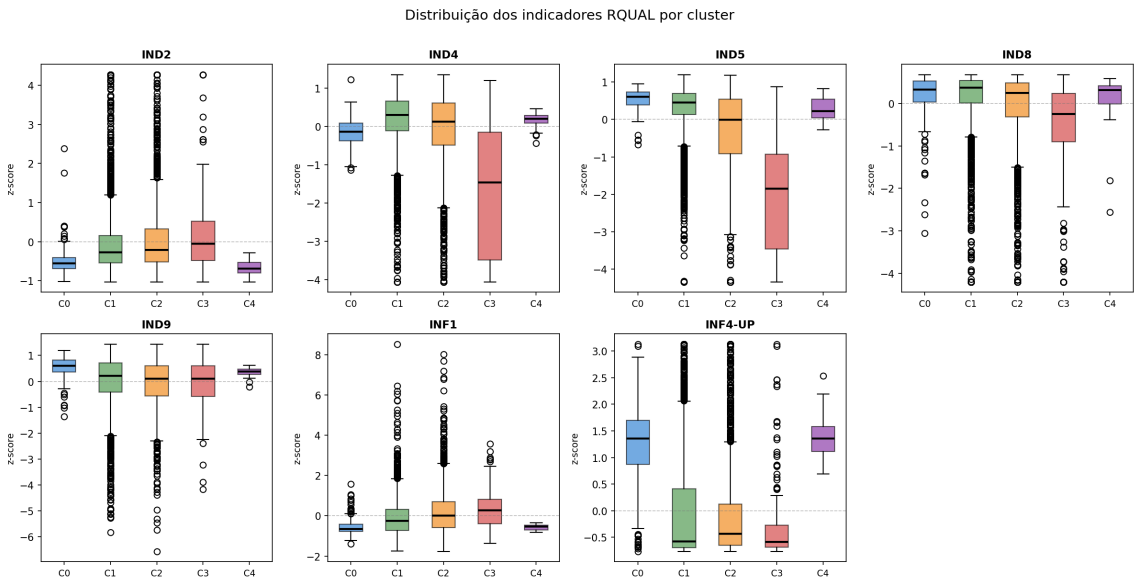

Interpretação dos clusters

C0 — Urbano-Avançado (216 municípios)

Municípios com maior desenvolvimento socioeconômico e melhor infraestrutura de telecom. Concentrados em SP (81), MG (30), RJ (25), RS (15) e PR (13). A qualidade do serviço acompanha o nível de renda e urbanização: alta taxa de resolução no prazo, poucas reclamações e throughput de upload excepcionalmente elevado.

C1 — Intermediário (3.054 municípios)

O cluster da "maioria silenciosa" — municípios com serviços adequados, sem problemas críticos. Representa o padrão de referência para políticas de manutenção de qualidade. Dominado por MG (754), SP (563), RS (481), PR (384) e SC (281).

C2 — Nordeste Periférico (2.057 municípios)

A infraestrutura chegou (INF1 acima da média), mas a qualidade operacional é inferior: taxa de resolução de problemas no prazo (IND5) abaixo da média e mais reclamações (IND2). Reflete o desafio de expansão sem maturidade operacional. PIB per capita (−0,44σ) e IDHM (−0,94σ) significativamente abaixo da média.

C3 — Norte/Amazônico (216 municípios)

Municípios de **alta vulnerabilidade**. Área territorial imenso (+1,89σ), população rural (+1,12σ) e economia primária (+0,79σ no VAB agropecuário) criam barreiras severas. IND5 = −2,09σ e IND4 = −1,70σ: os piores do país. **Prioridade máxima para políticas regulatórias.**

C4 — Capitais/Destaques (27 municípios)

Exatamente 1 município por UF — as capitais estaduais. Benchmark de qualidade: maior densidade (+2,06σ), maior upload (+1,38σ) e menor taxa de reclamações (−0,68σ). Referência do que é tecnicamente possível com investimento e densidade econômica adequados.

Achados HDBSCAN — Sub-estruturas dentro dos clusters

O HDBSCAN foi aplicado dentro de cada macro-cluster K-Means para revelar **exceções e subestruturas de densidade local**: municípios que fogem do padrão do seu próprio cluster — seja para melhor ou para pior. Esses são os achados mais acionáveis do framework.

> *Dos 5.570 municípios, **204 (3,7%)** formaram sub-clusters densos. Os demais foram classificados como ruído — casos intermediários sem vizinhança suficientemente densa.*

C3 Norte/Amazônico — dois sub-clusters revelam padrões opostos

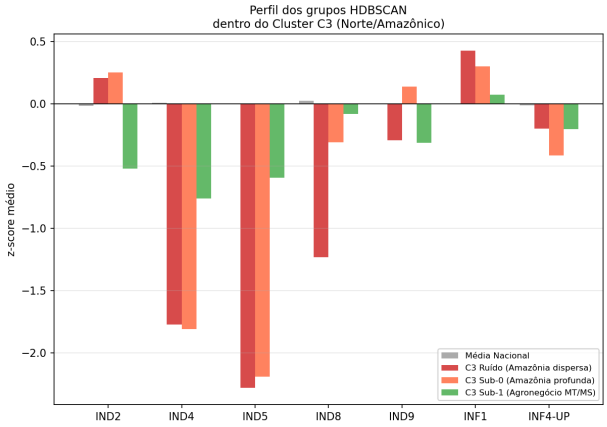

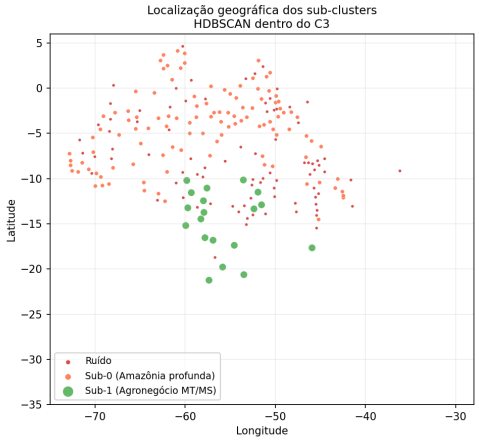

O cluster de pior qualidade do país esconde duas realidades distintas:

Grupo	Mun.	IND4	IND5	Perfil
Ruído	85	−1,77	−2,28	Pior de todos — sem conectividade nem qualidade operacional
Sub-0 — Amazônia profunda	112	−1,81	−2,19	PA, AM, AC, RR — atendimento crítico, mas IND9 acima da média (+0,14)
Sub-1 — Agronegócio MT/MS	19	−0,76	−0,59	**Exceção positiva** — remotos e rurais, mas com qualidade muito superior

Destaque — Sub-cluster 3001 (Agronegócio MT/MS): 19 municípios de Mato Grosso (15), Mato Grosso do Sul (3) e Minas Gerais (1) — Tangará da Serra, Campo Novo do Parecis, Canarana, Cáceres, Juína, entre outros. Apesar de serem municípios extensos e rurais com economia agropecuária (classificados como "Norte/Amazônico" pelo K-Means), a dinâmica econômica do agronegócio viabilizou qualidade de telecom muito acima dos vizinhos: IND5 salta de −2,19σ para −0,59σ. **São a prova de que o contexto geográfico não é impeditivo quando há investimento.**

C0 Urbano-Avançado — dois tipos de excelência

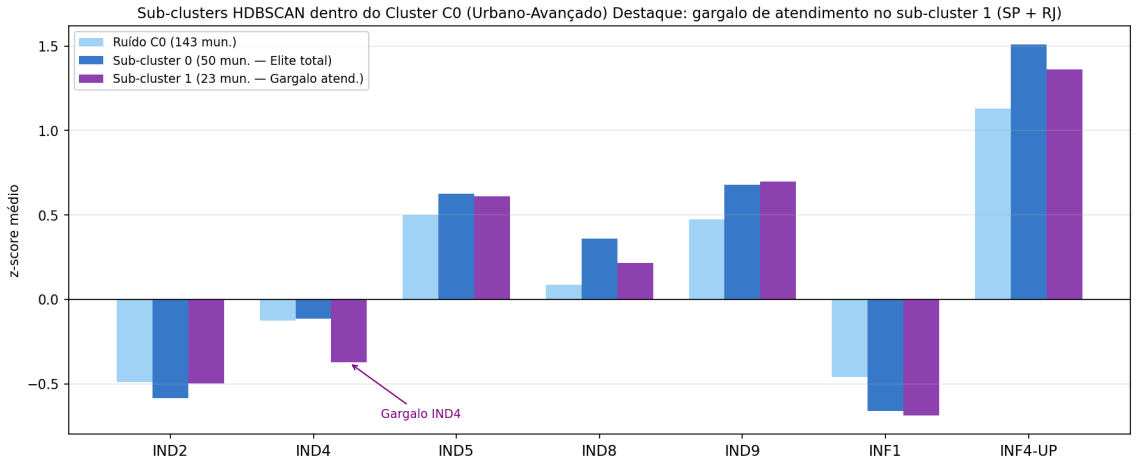

Dentro do melhor cluster, o HDBSCAN separou dois grupos distintos de alta performance:

Grupo	Mun.	IND4	INF4-UP	Perfil
Sub-0 — Elite total	50	−0,12	+1,51	SP (28), MG, RJ — topo absoluto em todos os indicadores
Sub-1 — Gargalo de atendimento	23	**−0,37**	+1,36	SP (11), RJ (6) — alta velocidade, mas atendimento sobrecarregado

Destaque — Sub-cluster 1 (Gargalo metrópoles): municípios de SP e RJ com infraestrutura de ponta (INF4-UP +1,36σ, IND9 +0,70σ) mas IND4 negativo — a taxa de atendimento cai porque o volume de chamados nas grandes metrópoles supera a capacidade das operadoras. Fenômeno de saturação operacional, não técnica.

Síntese dos achados HDBSCAN

Sub-cluster	Municípios	Insight chave
C3 Sub-1 — Agronegócio MT/MS	19	Exceção **positiva** no pior cluster: remotos, rurais, mas com boa qualidade
C3 Sub-0 — Amazônia profunda	112	Péssimo atendimento/prazo, mas velocidade razoável (possivelmente satelital)
C3 Ruído	85	Caso mais crítico: nem conectividade nem qualidade operacional
C0 Sub-0 — Elite total	50	Benchmark máximo nacional em todos os indicadores
C0 Sub-1 — Gargalo metrópoles	23	Qualidade técnica alta, mas saturação de atendimento em SP e RJ
C1, C2, C4	—	Sem sub-estruturas densas (grupos homogêneos, dispersos ou pequenos)

Implicações para políticas públicas

Eixo	Clusters-alvo	Problema	Indicadores-alvo
Expansão de Qualidade	C3 — Norte/Amazônico	SLA crítico em municípios remotos	IND4, IND5
Maturidade Operacional	C2 — Nordeste	Rede existe, atendimento falha	IND5, IND2
Manutenção e Benchmark	C0, C4	Replicar boas práticas	INF4-UP, IND8

Pipeline — O que foi feito em cada etapa

Notebook 01 — Leitura e Unificação RQUAL

`0-Fonte de Dados/RQUAL/XLSX/01-Leitura e união de todos os estados.ipynb`

Entrada: 12 arquivos XLSX por agrupamento de estados (ex: RQUAL_8ind-SP.xlsx, RQUAL_8ind-MG.xlsx...)
Saída: `base_RQUAL_unificada.parquet` — **5.962.723 linhas × 19 colunas**

O que foi feito:

- Leitura paralela com `ThreadPoolExecutor` (8 workers) — engine `calamine` preferido sobre `openpyxl` por performance
- Adição de coluna `__arquivo_origem` para rastreabilidade por estado
- Validação de duplicatas (zero encontradas)
- Cobertura: anos 2022, 2023, 2024 e 2025; 8 indicadores; todas as UFs

Decisões metodológicas: engine calamine reduz tempo de leitura ~3x vs openpyxl em arquivos grandes; leitura paralela em ~50s num Mac M4 vs ~4min sequencial.

Notebook 02 — Preparação do Ano Base

`0-Fonte de Dados/RQUAL/XLSX/02-Análise, Seleção e Preparação de ano base.ipynb`

Entrada: `base_RQUAL_unificada.parquet` (5,96M linhas)
Saída: `rqual_2022_consolidado_clean.parquet` — **5.570 linhas × 11 colunas** (1 linha por município)

O que foi feito:

- Filtro para ano base 2022 (único ano com cobertura completa dos 8 indicadores)
- Agregação municipal: média anual por indicador por município
- Imputação de missings por mediana da UF (fallback: mediana nacional)
- Validação: zero municípios sem cobertura após imputação
- Logs de auditoria gerados: `rqual_2022_log_imputacao.csv`, `auditoria_imputacao_resumo.csv`

Decisões metodológicas: 2022 escolhido como ano base por ser o único com todos os 8 indicadores disponíveis para a maioria dos municípios; anos posteriores têm cobertura parcial.

Notebook 03 — Agregação IBGE

`0-Fonte de Dados/IBGE/RAW/1-Agregacao_Dados_Socio-Economicos1_PATCHED.ipynb`

Entrada: 5 fontes IBGE independentes (PIB, população/área, urbanização, IDHM, lat/lon)
Saída: `base_socioeconomica_completa.xlsx` — **5.570 municípios × 56 colunas**

O que foi feito:

- Merge progressivo das 5 fontes pela chave `cod_mun` (código IBGE 7 dígitos)
- Normalização de nomes de municípios: remoção de acentos via Unicode NFKD para joins robustos
- Tratamento de inconsistências: municípios com nomes diferentes entre fontes (ex: "São Luís" vs "Sao Luis")
- Padronização de formatos de código municipal (truncagem para 7 dígitos)

Decisões metodológicas: `cod_mun` preferido sobre nome do município como chave de join — mais confiável por ser código numérico padronizado.

Notebook 04 — Integração RQUAL + IBGE

`1-Base Integrada - RQUAL+SocioEconomicos/03-Integracao e Analise de Variaveis RQUAL+SocioEc.ipynb`

Entrada: RQUAL 2022 (5.570 × 11) + IBGE (5.570 × 56)
Saída: `rqual_2022_integrado.parquet` — **5.570 linhas × 78 colunas**

O que foi feito:

- Join left por `cod_mun` — todos os 5.570 municípios preservados
- Validação de cobertura: zero municípios sem dados socioeconômicos após merge
- Análise exploratória das distribuições das 78 variáveis resultantes
- Identificação de variáveis candidatas para feature selection (numéricas e sem missings excessivos)

Notebook 05 — Feature Selection

`2-FeatureSelection/04-Seleção de feicoes.ipynb`

Entrada: `rqual_2022_integrado.parquet` (5.570 × 78)
Saída: `rqual_2022_feats_reduzidas.parquet` — **5.570 linhas × 20 features**

Pipeline de 6 etapas com logs de auditoria em cada passo:

Etapa	Método	Resultado
1. Higienização	Remoção de constantes e quasi-constantes (≥99% dominância)	41 variáveis avaliadas → 40 mantidas
2. Imputação	Mediana por UF com fallback mediana global	4 variáveis socioeconômicas imputadas
3. Robustez	Winsorização 1%–99% para variáveis com |skew| > 2	Aplicada em IND2, IND4, IND8 e outras
4. Z-score	Padronização (média=0, desvio=1)	Todas as features numéricas padronizadas

5. Correlação	Remoção de pares com $\|\rho\| \geq 0{,}80$ (preservando os 8 indicadores RQUAL)	**20 variáveis removidas**
6. VIF iterativo	Remoção iterativa até VIF ≤ 5,0 (tolerância 10,0 para RQUAL)	**1 variável removida**

Features finais (20): 7 indicadores RQUAL + PIB agropecuário + PIB industrial + PIB per capita + área + densidade + população rural + IDHM + lat + lon + 4 dummies de região geográfica

Logs gerados: `log_poda_correlacao.csv`, `log_vif_iterativo.csv`, `log_zscore_validacao_completo.csv`, `log_imputacao_socio.csv`, `log_robustez_transformacoes.csv`, `log_hig_avaliadas.csv`

Notebook 06 — Clustering K-Means + HDBSCAN

`3-KMeans+HDBSCAN/05-Kmeans.ipynb`

Entrada: `rqual_2022_feats_reduzidas.parquet` (5.570 × 20)
Saída: `rqual_2022_clusterizado.parquet` — **5.570 linhas com labels de cluster**

Escalonamento

- **Scaler escolhido:** RobustScaler (fração de outliers medida: **2,47%** — acima do limiar de 2%)
- Robusto a outliers vs StandardScaler, preservando a estrutura dos dados

Seleção de K

Avaliação de K=2 a K=12, **5 seeds aleatórias** (42, 7, 123, 2025, 99), 25 inicializações por rodada:

K	Silhouette	Calinski-Harabász	Davies-Bouldin	Score ponderado
2	0,831	5.659	0,743	−18,7 ✓ melhor silhouette
3	0,810	4.754	0,687	−17,9
5	**0,620**	**4.159**	**0,771**	**−28,3 ✓ escolhido**
6	0,620	4.322	0,713	−22,0
12	0,156	3.266	1,200	−51,5 pior

Por que K=5 e não K=2?
K=2 tem o maior silhouette (0,831), mas produz apenas 2 macro-grupos (Sul-Sudeste vs restante), perdendo as nuances do Nordeste, Norte e Capitais. O rank ponderado com pesos diferenciados (Calinski peso 2,0 > Davies peso 1,5 > Silhouette peso 1,2 > Inércia peso 1,0) favoreceu K=5 por equilibrar separação com granularidade interpretativa.

HDBSCAN (refinamento local)

- Aplicado dentro de cada macro-cluster K-Means para revelar subestruturas de densidade
- `min_cluster_size` = 3% do tamanho do cluster (mín. 10, máx. 150)

Artefatos gerados: `kmeans_model.pkl`, `scaler_final.pkl`, `kmeans_metricas_por_K.csv`, `kmeans_escolha_config.json`

Notebook 07 — Interpretação dos Clusters

`3-KMeans+HDBSCAN/06-Interpretacao_Clusters.ipynb`

Entrada: `rqual_2022_clusterizado.parquet`
Saída: 5 figuras + `tabela_resumo_clusters.csv`

O que foi feito:

- Heatmap de perfil médio por cluster (z-scores) em todos os indicadores
- Radar chart comparativo dos 7 indicadores RQUAL por cluster
- Mapa geográfico com coordenadas reais via `geobr` (centroides reprojetados para SIRGAS 2000)
- Distribuição regional (barras empilhadas por região)
- Box plots de cada indicador por cluster
- Narrativa interpretativa e implicações para políticas regulatórias

---

Instalação

```
git clone https://github.com/mfidosjr/Framework-Explicabilidade-Indicadores.git
cd Framework-Explicabilidade-Indicadores
pip install -r requirements.txt
```

> *Alguns arquivos XLSX de dados brutos (50–80 MB) são armazenados diretamente no repositório. Para arquivos maiores, use* `git lfs pull`.

Dados

Fontes

Fonte	Provedor	Cobertura	Volume
RQUAL	Anatel (dados abertos)	2022–2025, todos os estados	5,96M linhas
PIB Municipal	IBGE	5.570 municípios, 2021	—
Censo demográfico	IBGE	5.570 municípios, 2022	—
Taxa de urbanização	IBGE	5.570 municípios, 2022	—
IDHM	PNUD/Atlas Brasil	5.570 municípios, 2010	—
Geometria municipal	IBGE via geobr	5.570 municípios, 2020	—

Indicadores RQUAL

Indicador	Descrição	Interpretação
IND2	Taxa de Reclamações	Menor = melhor
IND4	Taxa de Atendimento	Maior = melhor
IND5	Taxa de Solução no Prazo	Maior = melhor

IND8	Disponibilidade do Serviço	Maior = melhor
IND9	Velocidade de Download	Maior = melhor
INF1	Cobertura/Infraestrutura	Maior = melhor
INF4-UP	Throughput Upload	Maior = melhor

Artefatos principais

Arquivo	Localização	Descrição
`base_RQUAL_unificada.parquet`	`0-Fonte de Dados/RQUAL/XLSX/`	RQUAL nacional (5,96M × 19)
`rqual_2022_consolidado_clean.parquet`	`0-Fonte de Dados/RQUAL/XLSX/`	RQUAL 2022 agregado por município
`rqual_2022_integrado.parquet`	`2-FeatureSelection/`	Base integrada RQUAL+IBGE (5.570 × 78)
`rqual_2022_feats_reduzidas.parquet`	`2-FeatureSelection/`	20 features selecionadas para clustering
`rqual_2022_clusterizado.parquet`	`3-KMeans+HDBSCAN/`	Resultado final com labels de cluster
`kmeans_model.pkl`	`3-KMeans+HDBSCAN/`	Modelo K-Means treinado (K=5)
`scaler_final.pkl`	`3-KMeans+HDBSCAN/`	RobustScaler ajustado
`kmeans_metricas_por_K.csv`	`3-KMeans+HDBSCAN/`	Métricas de avaliação K=2 a K=12
`tabela_resumo_clusters.csv`	`3-KMeans+HDBSCAN/`	Perfil médio por cluster

Módulos Python (`src/`)

Funções reutilizáveis extraídas dos notebooks:

Módulo	Funções principais
`data_loader.py`	`load_rqual_parallel()`, `load_ibge_socioeconomico()`, `load_parquet()`
`feature_engineering.py`	`impute_by_uf()`, `remove_high_correlation()`, `run_vif_iterative()`, `validate_zscore()`
`clustering.py`	`evaluate_kmeans_range()`, `choose_best_k()`, `run_hdbscan_per_cluster()`, `save_clustering_artifacts()`

Documentação técnica

- `Documentacao/RQUALCDUST10112022.pdf` — Manual técnico RQUAL (Anatel)

- `Documentacao/Glossario_de_Termos_Indicadores de Qualidade dos Serviços RQUAL_V2.odt` — Glossário de termos

Tecnologias

- Python 3.10+ · pandas · numpy · scipy
- scikit-learn (K-Means, métricas de clustering) · hdbscan · umap-learn
- pyarrow (Parquet) · openpyxl · python-calamine
- matplotlib · seaborn · geobr
- Jupyter Notebooks